

Receptų generavimas iš kulinarinių vaizdo įrašų naudojant vaizdo ir garso atpažinimo modelius

Rūta Kisieliūtė

Informatikos institutas

Matematikos ir informatikos fakultetas

Vilnius, Lietuva

ruta.kisieliute@mif.stud.vu.lt

Milda Domarkaitė

Informatikos institutas

Matematikos ir informatikos fakultetas

Vilnius, Lietuva

milda.domarkaite@mif.stud.vu.lt

Santrauka—Šiame projekte sukūrėme automatizuotą metodą receptų generavimui iš vaizdo įrašų pasitelkiant vaizdo ir garso atpažinimo modelius bei atlikome lyginamąjį modelių analizę. Naudojome BLIP, GIT ir KOSMOS-2 modelius analizuoti vaizdo kadrams bei Whisper modelį garso analizei. Gautus aprašus siuntėme į GPT-3.5-turbo - taip buvo gaunami receptai. Lyginamoji analizė atlikta vertinant sugeneruotų receptų panašumą į originalų turinį, naudojantis „HuggingFaceFV/finevideo“ duomenų rinkiniu. Darbas įgyvendintas Google Colab aplinkoje, sukurta vartotojo sąsaja.

Raktiniai žodžiai—Receptų generacija, vaizdo analizė, garso analizė, automatinis atpažinimas, BLIP, GIT, KOSMOS-2, Whisper.

I. ĮVADAS

Sparčiai tobulėjant vaizdo analizavimo bei generavimo priemonėms atsiranda vis daugiau galimybių analizuoti vaizdo įrašuose esančią informaciją. Šiame darbe sukurtas sprendimas, gebantis generuoti kulinarinius receptus iš vaizdo įrašų remiantis vaizdiniu bei garsiniu turiniu. Naudojami keli iš anksto apmokyti modeliai analizuoti vaizdo kadrams (BLIP, GIT, KOSMOS-2) bei kalbos/garso atpažinimo modelis Whisper. Sugeneruotos antraštės siunčiamos į OpenAI GPT-3.5-turbo modelį, kuris iš antraščių sugeneruoja nuoseklų ir logišką receptą. Sugeneruotos antraštės bei sugeneruoti receptai lyginami su originaliais duomenimis gautais iš duomenų rinkinio pasitelkiant lyginamąją analizę ir ingredientų tikrinimą. Sprendimas įvykdytas Google Colab aplinkoje, sukurta vartotojui patogi sąsaja vaizdo įrašų apdorojimui.

II. METODAI

A. Modeliai

Pagrindinei informacijos analizei naudojome 4 modelius: BLIP, GIT, KOSMOS-2 bei Whisper. Taip pat, receptų generavimui naudoti OpenAI GPT-3.5 bei kiti modeliai.

1) **BLIP**: BLIP (Bootstrapping Language-Image Pre-training) – tai modernus modelis, skirtas darbui su vaizdais ir teksta, galintis spręsti tiek vaizdų supratimo, tiek kalbos generavimo užduotis. Skirtingai nuo daugelio ankstesnių modelių, kurie paprastai specializuojasi tik vienoje srityje, BLIP yra universalesnis. Jis panaudoja iš interneto surinktus, dažnai netvarkingus vaizdo ir teksto duomenis, pasitelkdamas dviejų etapų „bootstrapping“ strategiją. Pirmiausia specialus modulis automatiškai sugeneruoja vaizdų aprašymus, o vėliau

kitas filtras atsirenka tik kokybišką ir prasmingą informaciją. Tokiu būdu modelis sugeba mokytis net iš neidealių, tačiau lengvai prieinamų duomenų šaltinių [2].

2) **GIT**: GIT (Generative Image-to-text Transformer) – tai generatyvinis modelis su vieninga architektūra, skirtas įvairioms užduotims, susijusioms su vaizdais ir tekstu. Jis gali generuoti vaizdų ar vaizdo įrašų aprašymus, taip pat atsakyti į klausimus apie vaizdinę informaciją. Skirtingai nuo ankstesnių metodų, kurie dažnai rėmėsi sudėtingomis daugiamodalinėmis sistemomis su papildomais komponentais: objektų detektoriais, žymių generatoriais ar OCR sprendimais – GIT pasižymi paprasta, vientisa struktūra. Jį sudaro tik du pagrindiniai elementai: vaizdo koduotuvas ir teksto dekoderis, kurie kartu atlieka kalbos modeliavimo užduotį. Toks dizainas leidžia pasiekti aukštus rezultatus išlaikant architektūros aiškumą ir efektyvumą [6].

3) **KOSMOS-2**: KOSMOS-2 – tai pažangus daugiamodalinis didysis kalbos modelis (MLLM), sujungiantis kalbos supratimą ir vizualinės informacijos interpretavimą. Jis ne tik geba generuoti tekstą ar analizuoti vaizdus, bet ir atlieka vadinamąjį „grounding“ – susieja konkrečias teksto dalis su vaizduose esančiais objektais. Be įprastų daugiamodalinių modelių gebėjimų, tokių kaip instrukcijų vykdymas ar kontekstinis mokymasis, KOSMOS-2 ypač tiksliai atpažįsta objektus ir gali generuoti tekstą, kuriame aiškiai nurodomi konkretūs vaizdo elementai [4].

4) **WHISPER**: Whisper – tai „OpenAI“ sukurtas pažangus automatinio kalbos atpažinimo (ASR) ir kalbos vertimo modelis, paremtas „Transformer“ architektūra. Tai sekos į seką (sequence-to-sequence) tipo sistema, išmokyta naudojant net 680 tūkstančių valandų įvairių garso ir teksto duomenų, surinktų iš interneto. Vienas pagrindinių Whisper pranašumų – ne tik didelis duomenų kiekis, bet ir jų įvairovė. Modelis buvo mokytas su daugiakalbiais duomenimis (117 tūkst. valandų – 96 kalbomis) bei kalbos vertimo pavyzdžiais (125 tūkst. valandų – iš kitų kalbų į anglų). Skirtingai nei daugelis kitų ASR modelių, Whisper nereikalauja papildomų žingsnių, tokių kaip savęs priežiūra (self-supervision) ar transkripcijos normalizavimas – jis tiesiogiai generuoja natūralius, sklandžius tekstus [5].

5) **GPT 3.5**: GPT-3.5-turbo – tai „OpenAI“ sukurtas pažangus generatyvinis kalbos modelis, veikiantis kaip tarpinė

versija tarp GPT-3 ir GPT-4. Jis pagrįstas transformerio architektūra ir specialiai optimizuotas pokalbiams – ypač per „chat completion“ sąsają. Dėl savo didelio greičio, efektyvumo ir mažesnių sąnaudų, šis modelis plačiai naudojamas įvairiose srityse – nuo tekstų generavimo ar santraukų kūrimo iki klausimų atsakymo ir instrukcijų vykdymo [3].

6) *Kiti modeliai:* Dar naudoti modeliai: all-MiniLM-L6-v2 modelis, tinkamas efektyviam semantinių ryšių nustatymui. all-mpnet-base-v2 - modelis, naudojantis pažangią MPNet architektūrą, kuri užtikrina aukštesnį tikslumą ir geresnį kontekstų supratimą, tačiau reikalauja daugiau skaičiavimo išteklių. Abu modeliai plačiai naudojami natūralios kalbos apdorojimo užduotims, tokioms kaip sakinių panašumo vertinimas ir teksto reprezentacija.

B. Modelių integracija

Vaizdo įrašų analizės procesą pradėjome nuo BLIP, GIT ir KOSMOS-2 modelių panaudojimo, siekiant sugeneruoti išsamius vaizdo įrašo kadro aprašymus. Garso įrašų transkripcijai apdoroti pasitelkėme Whisper modelį, kuris efektyviai išgavo tekstines garso įrašų transkripcijas. Vėliau perdavėme gautą informaciją GPT-3.5-turbo modeliui, kuris, remdamasis pateiktais duomenimis, parengė nuoseklius receptus.

C. Modelių palyginimo metrikos

Vaizdo-teksto modelius (Blip, Git, Kosmos) lyginome pagal preciziškumą, atpažinimą, F1 (1), generuotų antraščių/metaduomenų panašumą (2). Taip pat vertinome pagal tai, kiek procentų galutinio recepto duomenų yra antraštėse (6), bei kiek šių sutampančių duomenų egzistuoja metaduomenyse (7).

$$\begin{aligned} \text{Preciziškumas} &= \frac{|\text{antraštės atitikusios metaduomenis}|}{|\text{antraštės}|} \\ \text{Atkūrimas} &= \frac{|\text{metaduomenys atitikę antraštes}|}{|\text{metaduomenys}|} \\ F_1 &= \frac{2 \cdot \text{Preciziškumas} \cdot \text{Atkūrimas}}{\text{Preciziškumas} + \text{Atkūrimas}} \end{aligned} \quad (1)$$

Kiekvienam prognozės indeksui i nustatomas atitinkamas nuorodos indeksas j , toks kad kosinuso panašumas $\text{sim}_{i,j}$ būtų maksimalus:

$$j = \arg \max_k \text{cosine_scores}_{i,k} \quad (2)$$

Jei $\text{sim}_{i,j} \geq \text{threshold}$, indeksas i pridedamas prie sutapusių prognozių aibės, o j – prie sutapusių nuorodų aibės:

$$\text{matched_preds} \leftarrow \text{matched_preds} \cup \{i\} \quad (3)$$

$$\text{matched_refs} \leftarrow \text{matched_refs} \cup \{j\} \quad (4)$$

Whisper modelį vertinome pagal generuoto „text-to-speech“ (TTS) teksto ir automatinės transkripcijos semantinį panašumą, apskaičiuotą naudojant vidutinį maksimalų kosinuso panašumą.

Prognozės indeksams skaičiuojamos taip pat kaip nurodyta (2) formulėje.

Tuomet apskaičiuojamas vidutinis maksimalus panašumas tarp visų prognozių ir nuorodų eilučių:

$$\text{Vidutinis_panašumas} = \frac{1}{m} \sum_{i=1}^m \max_{j \in [1,n]} (\cos(\mathbf{p}_i, \mathbf{r}_j)) \quad (5)$$

Kur:

- m – prognozuotų (TTS) eilučių skaičius,
- n – nuorodinių (Whisper) eilučių skaičius,

Ši metrika leidžia įvertinti, kiek semantiškai artimas yra metaduomenų TTS tekstas gautai Whisper kalbos transkripcijai. Rezultatas pateikiamas skalėje nuo 0 iki 1, kur 1 reiškia tobulą atitikimą.

Taip pat visus modelius vertinome pagal tai, kiek galutinio recepto (generuoto su GPT-3.5 iš vaizdo-teksto ir garso-teksto modelių sugeneruotų antraščių) ingredientų yra randama tose pačiose antraštėse. Taip pat skaičiuota, kiek galutiniame recepte ir antraštėse sutapusių ingredientų (toliau - receptų-antraščių ingredientų) buvo rasta metaduomenyse, bei vykdyti iš šios informacijos išplaukiantys palyginimai. Tikslesnė šio vertinimo eiga matoma diagramoje „1 pav.“.

Buvo skaičiuojamos šios pagrindinės metrikos:

- Receptų ingredientų radimas antraštėse procentas (be sinonimų),
- Receptų ingredientų radimas antraštėse procentas (naudojant GPT-3.5 sugeneruotus 6 sinonimus),
- Receptų-antraščių ingredientų radimas metaduomenyse procentas (be sinonimų),
- Receptų-antraščių ingredientų radimas metaduomenyse procentas (naudojant GPT-3.5 sugeneruotus 6 sinonimus)

Pagal formules:

$$\text{Atitikimas}_1 = \frac{|\text{antraštėje rasti recepto ingredientai}|}{|\text{visi recepto ingredientai}|} \cdot 100 \quad (6)$$


$$\text{Atitikimas}_2 = \frac{|\text{metaduomenyse rasti receptų-antraščių ing.}|}{|\text{visi receptų-antraščių ingredientai}|} \cdot 100 \quad (7)$$

Papildomai buvo skaičiuotas ingredientų kiekio padidėjimas taikant sinonimus procentais:

$$\text{Sinonimų_nauda} = \frac{|\text{su sinonimais} - \text{tikslūs}|}{|\text{tikslūs}|} \cdot 100 \quad (8)$$

Bei vidutinis konkretaus modelio rastų ingredientų kiekio procentas lyginant su visų modelių rastu ingredientų kiekiu (tiksliai ir su sinonimais):

$$\text{Vid_rasta} = \frac{100}{N} \sum_{i=1}^N \frac{|\text{konkreto modelio rasti ingredientai}_i|}{|\text{visų modelių rasti ingredientai}_i|} \quad (9)$$



1 pav. – Ingredientų radimo ir vertinimo eiga


III. DUOMENYS

Šiam darbui atlikti naudoti duomenys iš „HuggingFaceFV/finevideo“ duomenų rinkinio, pasirinkus kategorijos „Lifestyle“ subkategoriją „Recipe videos“ [1]. Kiekvienas pavyzdys buvo filtruojamas pagal metaduomenyse nurodytą lauką `content fine category`, siekiant atsirinkti tik aktualų turinį. Iš viso buvo parsisiųsta 100 vaizdo įrašų, tačiau, įvertinus jų kokybę ir informatyvumą, analizei buvo palikti tik 65 vaizdo įrašai, pašalinus nekokybiškus ar nenaudingus pavyzdžius. Prieš pradedant duomenų analizę, visi vaizdo įrašai buvo automatiškai suskaidyti į atskirus kadrus – po vieną kadrą kas sekundę. Sugeneruoti kadrai buvo išsaugoti atskiruose aplankuose pagal vaizdo pavadinimus ir naudoti trimis vaizdo aprašymo modeliams (BLIP, GIT, KOSMOS-2). Ketvirtam modeliui – Whisper – buvo naudojama tik vaizdo įrašų garso

takelio analizė, pasitelkiant automatinio kalbos atpažinimo metodą. Be vaizdo ir garso duomenų, analizėje taip pat plačiai naudoti kiekvienam vaizdo įrašui priskirti metaduomenų failai (.json), kuriuose pateikiami itin išsamūs ir naudingi scenų, veiklų bei pasakojimo eigos aprašymai. Šie metaduomenys buvo ypač vertingi tiek vertinant modelių sugeneruotų aprašų kokybę, tiek ingredientų atpažinimo tikslumą.


IV. REZULTATAI

Įvertinus visus duomenis, suskaičiavome metrikas vaizdų-teksto modeliams Blip, Git, Kosmos-2 bei garso-teksto modeliui Whisper ir gautus duomenis pavertėme diagramomis ir lentelėmis.



2 pav. – F1 visuose vaizdo įrašuose.

Diagramoje „2 pav.“ matome, kaip pasiskirstė F1 metrikos Blip, Git ir Kosmos-2 modeliams pagal kiekvieną vaizdo įrašą. Pagal tokį metrikų išsidėliojimą matoma, jog metrikos priklauso ne tik nuo naudojamo modelio, bet ir yra aiški koreliacija tarp visų 3 modelių metrikų režių ir vaizdo įrašo, kuris buvo vertinamas, todėl metrikos stipriai remiasi į tai, kokios kokybės duomenys buvo pateikti.




3 pav. – Panašumo vidurkis visuose vaizdo įrašuose.

Modelių sugeneruotų antraščių ir metaduomenų panašumo tikrinimo diagramoje „3 pav.“ tai pat išryškėja metrikų priklausomybė pradinių duomenų kokybei. Pvz.: vaizdo įrašė „Sample_16“ tik vienoje vaizdo įrašo pusėje vyksta gaminimas. Metaduomenyse tai yra išskirta ir recepto vaizdas vertinamas atskirai nuo kito įrašo, tačiau modeliai generuojantys antraštes iš vaizdo segmentų tokio atskyrimo neturi ir visą segmentą vertina kaip vieną visumą, dėl ko atsiranda teksto panašumo skirtumai.

Diagramoje „4 pav.“ matomi metrikų vidurkiai 3 vaizdo-teksto modeliams. Aukščiausius balus vidutiniškai turi Kosmos-2 modelis, todėl galima daryti prielaidą, jog jis veikia efektyviausiai. Toliau seka Git ir galiausiai Blip modeliai.

Jei lyginsime modelius pagal kiekvieną metriką atskirai – matysime šiek tiek kitokį vaizdą, nors tendencija ir išlieka ta



4 pav. – Vidutinės metrikos kiekvienam modeliui.

I lentelė – Modelių preciziškumo palyginimas

Preciziškumas	
Modelis	Vertė
BLIP	0.28
GIT	0.26
KOSMOS-2	0.37

pati. Lentelėje „I lentelė“ matome preciziškumo metriką, kurioje geriausiai pagal vidutinį duomenų įvertį veikia Kosmos-2 modelis, toliau seka Blip ir Git modeliai. Lentelėje „II lentelė“ aukščiausią atkūrimo balą turi Git modelis, toliau seka Kosmos ir Blip. Aukščiausią F1 įvertį lentelėje „III lentelė“ turi Kosmos-2 modelis, antras pagal gerumą yra Git, o Blip vėl yra paskutinis. Galiausiai, žiūrint į panašumo vidurkį lentelėje „IV lentelė“ matome, jog Kosmos-2 vėl yra pirmoje vietoje, Git antroje, o Blip trečioje. Taigi, iš 3 vaizdo-teksto modelių Kosmos veikia geriau $\frac{3}{4}$ metrikų, Git $\frac{1}{4}$, o Blip $\frac{3}{4}$ metrikų liko paskutinis.

Garso-teksto modelio metrikas galime matyti „5 pav.“ diagramoje. Whisper modelio sugeneruotas tekstas buvo lygi-

II lentelė – Modelių atkūrimo palyginimas


Atkūrimas	
Modelis	Vertė
BLIP	0.26
GIT	0.41
KOSMOS-2	0.33

III lentelė – Modelių F1 reikšmės

F1	
Modelis	Vertė
BLIP	0.25
GIT	0.30
KOSMOS-2	0.33


IV lentelė – Modelių panašumo vidurkis

Panašumo vidurkis	
Modelis	Vertė
BLIP	0.40
GIT	0.39
KOSMOS-2	0.44



5 pav. – Whisper modelio ir metaduomenų TTS vidutinis kosinuso panašumas.


namas su metaduomenų „text_to_speech“ skiltimi. Pasitelkus Vidutinį kosinuso panašumą matome, jog modelis veikia labai gerai ir tik 1 kartą panašumas buvo mažesnis nei 0,8. Tačiau svarbu paminėti, jog iš šio skaičiavimo buvo išimti vaizdo įrašai, kuriose kalbama ne anglų kalba. Taip yra dėl to, jog nors Whisper modelis ir yra pajėgus atpažinti kitas kalbas ir atpažinus garsą išversti duomenis į anglų kalbą, tačiau metaduomenų faile „text_to_speech“ duomenys, jei kalbama kita kalba, neturi logiškos ir teisingos informacijos.




6 pav. – Metrikos kiekvienam vaizdo įrašui - tikslus radimas antraštėse.

Diagrama esanti „6 pav.“ atvaizduoja kaip skiriasi 3 vaizdo-teksto bei 1 garso-teksto modelio rezultatai bandant procentaliai perteikti kiek buvo rasta sutampančių ingredientų galutiniuose receptuose (gaunamuose su GPT-3.5 iš atitinkamų modelių antraščių) ir modelių sugeneruotose antraštėse. Matome, jog šiame lyginyje pradinio vaizdo įrašo turinys įprastai neturi tiesioginės koreliacijos su tuo, kaip šioje metrikoje pasirodo modeliai, taigi tam pačiam vaizdo įrašui, pvz.: „Sample_19“ Blip gali turėti 0% sutampančių duomenų radimą, kol Kosmos-2 modelis antraštėse rado visus galutiniame recepte įvardytus ingredientus.


Tęsiant ingredientų palyginimą, patogu žvelgti į metrikų vidurkius pagal modelį. Diagramose esančiuose paveikslėliuose „7 pav.“, „8 pav.“, „9 pav.“, „10 pav.“ galime matyti tokius duomenis:




7 pav. – Metrikų vidurkis - tikslus radimas antraštėse.



10 pav. – Metrikų vidurkis - sinonimų radimas metaduomenyse.



8 pav. – Metrikų vidurkis - sinonimų radimas antraštėse.




9 pav. – Metrikų vidurkis - tikslus radimas metaduomenyse.

1. Kiek procentų galutinių receptų ingredientų buvo rasta lyginant su atitinkamo modelio antraštėmis (tiksliai įvardytų ingredientų ir įvardytų ingredientų arba jų sinonimų).

2. Kitose lentelėse – kiek procentų receptų-antraščių ingredientų buvo rasta atitinkamame metaduomenų faile (tiksliai ingredientų ir su sinonimais).

Iš šių lentelių matome, jog visais atvejais tarp teksto-vaizdo modelių geriausiai pasirodė Kosmos-2 modelis. Toliau sekė

Git modelis ir galiausiai Blip. Taigi su Kosmos-2 modelio sugeneruotomis antraštėmis GPT-3.5 modelis ne tik mažiau- siai „prikūrė“ naujų ingredientų galutiniam receptui, bet ir geriausiai atrinko, kokie ingredientai realiai buvo naudojami recepte. Lyginant vaizdo-teksto modelius (Blip, Git, Kosmos-2) su garso-teksto modeliu Whisper, matome Whisper modelio pranašumą. Taip yra todėl, kad garso modelis neturi „spėlioti“ kaip tiksliai ar abstrakčiai įvardinti vieną ar kitą ingredientą, negali sumaišyti panašiai atrodančių ingredientų. Taigi, jei vaizdo įrašas turi garsą ir jame yra nupasakojama kas vyksta (nesvarbu kuria kalba) – mūsų tirtas garso-teksto modelis turi pranašumą prieš nagrinėtus vaizdo-teksto modelius.




11 pav. – Vidutiniškai rasta pagal modelį ir metriką.


Diagrama pateikta „11 pav.“ padeda lengvai palyginti kaip skiriasi visų modelių ingredientų radimas tiek tarp galutinio recepto ir antraščių, tiek tarp receptų-antraščių ir metaduomenų atsižvelgiant į tai, ar buvo ieškoma konkrečių ingredientų, ar ingredientų bei jų sinonimų. Visi modeliai (vaizdo-teksto ir garso-teksto) su sinonimais veikia maždaug 15-23% geriau nei imant tik tiksliai įvardintus ingredientus. Taip nutinka dėl 2 priežasčių:

1. Vaizdo-teksto modeliai nežino, kokio tikslumo duomenų reikia, todėl jei metaduomenyse buvo paminėta paprika, o modelis „pamatė“ raudoną papriką – sinonimai padeda atpažinti, kad paprika ir raudona paprika yra tas pats.


2. Sudarinėjant ingredientus iš antraščių, GPT-3.5 modelis gali panaudoti pagal recepto kontekstą labiau tinkantį sinonimą vietoj to, ką gavo iš antraščių. Taigi, tikrinant su sinonimais, šis pakeitimas gali būti „atkeistas“.




12 pav. – Blip - sinonimų radimas metaduomenyse.



13 pav. – Git - sinonimų radimas metaduomenyse.




14 pav. – Kosmos - sinonimų radimas metaduomenyse.



15 pav. – Whisper - sinonimų radimas metaduomenyse.


Lentelėse „12 pav.“, „13 pav.“, „14 pav.“, „15 pav.“ matome receptų-antraščių ingredientų lyginimą su metaduomenimis pasitelkiant sinonimus, išskirstytus pagal modelį kiekvienam vaizdo įrašui. Iš šios informacijos matome, jog skirtingi modeliai gali labai gerai dirbti su vienais įrašais, tačiau tragiškai su kitais. Taigi, tęsiant darbą ir atliekant gilesnę analizę, įmanoma pagerinti modelių tikslumą juos specializuojant pagal tai, su kokių specifikacijų vaizdo įrašais jie dirba geriausiai.

Lyginant kiek vidutiniškai iš viso vienam vaizdo įrašui (per visus 4 modelius) buvo rasta ingredientų (recepto-antraščių ingredientų esančių ir metaduomenyse) ir kiek iš jų procentais buvo rasta su konkrečiu modeliu, patogu žvelgti į „16 pav.“ diagramą. Čia matome, jog tarp vaizdo-teksto modelių geriausiai pasirodė Kosmos-2, o lyginant visus 4 modelius – Whisper. Norint turėti aiškesnį supratimą, kodėl taip skiriasi



16 pav. – Vidutiniškai rasta ingredientų (tiksliai vs su sinonimais).

tikslių ingredientų ir su sinonimais statistikos, reikia atsižvelgti į dar vieną diagramą.



17 pav. – Ingredientų padidėjimas lyginant pagal sinonimus.

„17 pav.“ esančios diagramos duomenys rodo, kiek procentais padidėja ingredientų skaičius per visus 4 modelius, jei skaičiuojami ingredientai su sinonimais. Kaip matome, priklausomai nuo vaizdo įrašo, ingredientų skaičius gali nepakisti arba išaugti net iki 267%. Taigi, atsižvelgiant į šią informaciją, ir vėl pažvelgę į „16 pav.“ diagramą, galime matyti, jog nors dėl mažesnių procentų metrikose su sinonimais ir atrodo, jog buvo rasta mažiau ingredientų, tačiau iš tiesų - jų buvo rasta daug daugiau - tiesiog išaugo ir visų modelių ingredientų skaičius, dėl ko procentinė vertė krito.

V. IŠVADOS

Apibendrinant vaizdo-teksto modelių efektyvumo analizę recepto kūrimo iš vaizdo įrašo užduotyje, nustatyta, kad iš trijų lygintų modelių (BLIP, GIT ir KOSMOS-2) geriausių rezultatų demonstravo Kosmos – jis pranoko kitus du modelius beveik visose vertinimo metrikose. Vis dėlto, jei lyginsime vaizdo-teksto modelius su garso-teksto modeliu (Whisper), geriau pasirodė garso-teksto modelis. Tačiau tai nereiškia, jog testuojant bet kokią vaizdo įrašą geriau pasirodys garso-teksto modelis, kadangi recepto vaizdo įrašė neprivalo būti garsas arba jis gali būti nereikšmingas. Siekiant išsamesnių įžvalgų ateities tyrimuose būtų galima įtraukti daugiau garso-teksto modelių ir padidinti vaizdo įrašų diversifikuotumą bei sinonimų apimtį.

LITERATŪRA

- [1] HuggingFaceFV. Finevideo: A multimodal dataset for fine-grained video understanding. <https://huggingface.co/datasets/HuggingFaceFV/finevideo>, 2023. Accessed: 2025-05-20.
- [2] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. *International Conference on Machine Learning*, 2022:12888–12900, 2022.
- [3] OpenAI. GPT-3.5 Turbo model overview. <https://platform.openai.com/docs/models/gpt-3.5-turbo>, 2023. Accessed: 2025-05-19.
- [4] Zhiliang Peng, Weizhen Wang, Li Dong, Yelong Hao, Shuming Huang, Shujie Ma, and Furu Wei. Kosmos-2: Grounding multimodal large language models to the world. *arXiv preprint arXiv:2306.14824*, 2023.
- [5] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. *International Conference on Machine Learning*, 2023:28492–28518, 2023.
- [6] Jianfeng Wang, Zhengyuan Yang, Xiaowei Hu, Linjie Li, Kevin Lin, Zhe Gan, Zicheng Liu, Ce Liu, and Lijuan Wang. Git: A generative image-to-text transformer for vision and language. *arXiv preprint arXiv:2205.14100*, abs/2205.14100, 2022.